

陈选安

(+86) 178-2650-7955 · 623894679@qq.com · AI Infra / 推理引擎工程师 · GitHub @PatchouliTIS

教育背景

中国科学技术大学, 软件工程, 硕士研究生 2022.09 - 2025.06
GPA 3.4/4.3 (TOP 25%), 研究生二等奖学金。主修: 分布式系统与云计算、深度学习、机器学习
长安大学, 道路桥梁与渡河工程, 工学学士 2015.09 - 2019.06
GPA 3.7/5.0 (TOP 10%), 院级一等奖学金。主修: C++ 程序设计、Python 程序设计、数据结构

技术能力

- 编程语言: 熟悉 C++ 面向对象编程与现代 C++ 语言特性; 熟悉 Python, Golang; 熟悉 Linux 系统开发
- AI 推理优化: 熟悉 PyTorch, TensorFlow; 熟悉 vLLM, TensorRT-LLM 等大模型推理框架; 拥有 CUDA/Triton/CUTLASS 算子开发经验, 掌握张量并行、模型并行、序列并行等分布式训练概念; 掌握常用的神经网络推理优化方法 (量化、投机解码、算子融合等)
- 工程组件: 熟悉 Kafka, ElasticSearch, Docker, CMake, Git; 了解 Kubernetes 基本概念

工作经历

腾讯 | TEG 混元机器学习平台, 推理引擎工程师 2025.06 - 2026.04

- INT8 Blockwise W8A8 量化推理优化** (专利成果) | 背景: LLM 推理中 INT8 量化是降低显存、提升吞吐的关键手段, 但 Ampere 硬件上量化算子频繁执行数值转换严重影响性能。核心主导该方案从算法设计到端到端集成的全栈开发, 代码量 ~7200 行 (CUDA 2200+, Triton/Python 3500+)。提出 Hybrid 二级 Scale 量化方案, 将 FP32 scale 分解为 (Q_int32, F_fp32) 实现 K-Tile 维度连续 INT32 累加, 消除 mainloop 中全部浮点指令; 基于 CUTLASS 开发 3 种 CTA Tile 配置的 GEMM kernel 并实现 CTA Swizzle 优化 L2 缓存命中率; 设计三级融合策略将激活在线量化的多步算子垂直融合为单 kernel。Tensor Core 利用率从 48% 提升至 65%, 算子时延降低 1.23x~1.47x, Qwen3-8B 端到端 QPS 相比 BF16 提升 1.67x~2.24x。
- Async N-gram GPU 投机解码** (PR #29184 合入 vLLM 主线) | 背景: vLLM 异步调度器通过重叠 CPU/GPU 提升吞吐, 但 N-gram 投机解码依赖 CPU 逐 token 采样, 每步需 CPU-GPU 同步成为瓶颈。作为项目 owner 将 N-gram Proposer 完全迁移至 GPU, 利用 Torch 向量化操作将 CPU O(N) 查找优化为滑动窗口 O(1) 并行匹配; 实现异步 D2H、Pinned Memory 复用、独立 CUDA Stream 等零同步设计, 解除 CPU-GPU 同步阻塞。H20 上 64~512 并发吞吐提升 20%~39%。
- DivPrune 视觉 Token 剪枝** | 背景: 多模态模型处理视频流时 encoder 阶段 vision token 过多导致显存与计算瓶颈。在 Qwen3-VL 中设计并实现基于最远点采样 (Farthest-Point Sampling) 的特征多样性剪枝方法, 采用批量并行选取 (parallel_k=32) + mRoPE 3D 位置编码附加方案, 实现 EVS/DivPrune/关闭三种模式无缝切换, 保持完全向后兼容。Qwen3-VL 视频 Caption 等业务场景端到端吞吐提升 1.2x~1.34x。
- Penalty-Aware Speculative Decoding** | 背景: Speculative Decoding 中多 draft token 并行采样时, frequency/presence penalty 无法感知同批次更早位置的 token, 导致计算错误。设计增量计数机制, 在 Triton kernel 中以 BLOCK_SIZE 粒度向量化匹配 vocab ID 并动态累加前置 draft token 出现次数; 利用 tl.static_range 编译期循环展开避免动态循环开销。修正多 draft token 并行采样时的惩罚计算错误, 保证生成约束正确性, 性能开销可控。

实习经历

微软 | Bing Core Search, 推理引擎性能优化工程师 2023.10 - 2024.12

- KV Cache 压缩优化** | 背景: LLM 推理中 KV Cache 显存占用随序列长度线性增长, 成为长文本推理瓶颈。基于注意力分数实现 KV Cache 压缩, 使用 Triton 编写 Prefill 阶段 Block-Sparse Attention kernel, 结合 CUDA 内存搬运函数与 vLLM CacheEngine 实现动态压缩存储。达到 60% 压缩率, 4x kernel 加速比, A100 上 LLaMa-7B P95 时延从 9.8s 优化到 6.3s。
- Online TopK 算子融合** | 背景: 搜索排序模型中张量点积与 TopK 分步执行带来额外 kernel launch 与显存搬运开销。使用 CUTLASS & CuTe 框架, 运用 Tensor Core、异步 IO、并行 Bitonic TopK 实现张量点积与 TopK 算子垂直融合。时延从 30ms 压缩至 11ms (3x 加速比)。
- Labeling 模型量化部署** | 背景: Labeling 模型在线推理延迟过高影响搜索服务质量。针对 compute-bound 场景采用 SmoothQuant、memory-bound 场景采用 GPTQ 量化部署。P95 延迟从 6.7s 降至 4.4s。
- 搜索排序模型优化** | 背景: BERT 排序模型训练效率低制约迭代速度。引入 RoPE 位置编码蒸馏训练, 使用 DeepSpeed ZeRO-2 + FP16 在 8xA100 上训练。达到基线 8x 训练速度。

开源贡献

- vLLM 核心贡献者**: 多项 PR 合入主线, 涵盖 INT8 量化推理、投机解码 GPU 化、视觉 Token 剪枝、Penalty-Aware 采样修正、Eagle3 Hidden States 导出等方向
- GitHub: <https://github.com/PatchouliTIS>