

陈选安

(+86) 178-2650-7955 · pyramkar@qq.com · AI Infra / 推理引擎工程师 · GitHub @PatchouliTIS

个人简历

从事大模型推理引擎优化，专注推理框架（vLLM）优化与 GPU 算子开发（CUDA/CUTLASS/Triton），在量化推理、投机解码、多模态剪枝等方向有端到端优化落地经验，支撑混元多模态以及语言模型千万级离线数据打标和在线推理业务，vLLM 核心 Feature 贡献者。

工作经历

腾讯 | TEG 混元机器学习平台, 推理引擎工程师 2025.06 - 2026.06

- Eagle3** 投机解码草稿模型训练 | 多模态草稿模型训练与部署
优化 Eagle3 speculators 训练框架对 Qwen3.6 Hybrid Attention 及多模态模型的适配；设计 PartialM-RoPE 使训练框架支持 $\text{partial_rotary_factor} < 1$ 的部分旋转与 MRoPE 3D 位置编码；设计并实现针对图片 Caption 垂类任务的草稿模型训练流程；设计加权 KL+CE 混合损失函数，首字接受率额外提升 **9%~10%**；修复 speculators 训练框架中多模态数据预处理链路无法正确处理多模态 padding token 的问题，使训练器草稿模型能正确感知多模态数据。**Qwen3.6-35B-A3B** 多模态 **Caption** 任务首位 **draft token** 接受率 **80%**，**batchsize 256** 端到端吞吐提升 **1.37x**，优于原生 **MTP**。
- Async N-gram GPU** 投机解码 | 消除投机解码流程中 CPU-GPU 同步瓶颈
针对 vLLM 异步调度下 N-gram 投机解码依赖 CPU KMP 算法导致 GPU 空泡的瓶颈，将 N-gram Proposer 匹配算法用 GPU 向量化操作重构，时间复杂度从 $O(BN)$ 降至 $O(1)$ ；设计并实现纯 GPU 侧 metadata 更新逻辑以减少 CPU 同步开销；发现并修正投机解码中多 batch draft token 并行采样时 frequency/presence penalty 无法感知同批次前置 token 的计算错误；设计增量计数机制并在 Triton kernel 中以 BLOCK_SIZE 粒度向量化匹配，利用编译期循环展开消除动态开销。**H20** 上 **64~512** 并发吞吐提升 **23%~45%**；修正惩罚计算错误，保证生成约束正确性，性能开销可控。
- INT8 Blockwise W8A8** 在线量化推理优化 | 全栈量化方案设计与落地
针对 Ampere 架构 INT8 在线量化中 Tensor Core 利用率低（仅 44%）的瓶颈，设计 Hybrid 二级 Scale 量化算法，将 FP32 scale 分解为 (Q_int32, F_fp32)，使 GEMM 主循环全程保持 INT32 累加，仅在 Epilogue 做一次浮点转换，**TensorCore** 利用率从原始 **44%** 提升至 **57%~65%**；基于 CUTLASS 开发多 Tile 配置 GEMM Kernel；手动 overlap 地址计算与 IMMA 计算；优化 L2 局部性；通过 Triton 实现激活量化前后算子垂直融合。**Dense** 算子端到端时延降低 **69%~117%**，**Qwen3-8B QPS** 提升 **67%~103%**；**MoE** 算子时延降低 **46%~84%**，**Qwen3.6-35B-A3B QPS** 提升 **38%~423%**。
- DivPrune** 视觉 **Token** 剪枝 | 多模态推理显存与计算优化
针对多模态模型处理视频流时 vision token 过多导致的显存与计算瓶颈，设计基于最远点采样的特征多样性剪枝方法；采用批量并行选取策略替代逐 Token 贪心，设计 MRoPE 3D 位置编码附加方案保证剪枝后文本 token 位置信息可恢复；引入可配置的 Micro-Batch 机制，解决了 Scheduler 按剪枝后 Token 数估算显存导致视觉编码器 OOM 的问题。**Qwen3-VL** 视频 **Caption** 场景端到端吞吐提升 **1.2x~1.34x**。
- 多模态高吞吐结构化抽取 | Train-Aligned One-Prefill 架构
提出 Train-Aligned One-Prefill 框架，基于 Qwen3.6-35B-A3B 语音分类任务优化，外挂极轻量级 SlotClassifier 分类头，提取因果隐状态 $h_d = H[p_{d-1}]$ 进行分类，消除训练-推理分布偏移与词表先验偏差；引入 valid_mask 机制结合 torch.einsum 与 torch.gather，摒弃循环 Linear Head 设计，实现全维度 Logits 向量化计算；设计逆词频平方根归一化权重与信息熵维度权重解决长尾类别坍塌，定制 Masked Label Smoothing 规避 $-\infty$ 计算的 NaN 陷阱；搭建 Teacher-Student 蒸馏 Pipeline，以高精度自回归模型为 Teacher 提供软标签，通过 L_{KD} 引导分类头训练，还原语义理解能力。移除自回归解码，推理吞吐提升 **2.17** 倍，**12** 维属性平均准确率提升 **23%**。

实习经历

微软 | Bing Core Search, 推理引擎性能优化工程师 2023.10 - 2024.12

- 在线稀疏注意力优化 | 长文本推理优化
针对超长上下文（40k input tokens）推理中，注意力模块耗时随着 sequence 纬度指数级增长的痛点，基于 QK 注意力分数实现在线的块状稀疏注意力，使用 Triton 编写 Prefill 阶段 Block-Sparse Attention kernel，结合 CUDA 内存搬运与 vLLM CacheEngine 实现动态压缩存储。在 **40k** 上下文推理中达到 **67%** 压缩率，**4x kernel** 加速比，**A100** 上 **LlaMa-7B P95** 时延从 **9.8s** 降至 **6.3s**。
- Online TopK** 算子融合 | 搜索排序模型推理加速
针对搜索排序模型中张量点积与 TopK 分步执行的额外开销，使用 CUTLASS & CuTe 框架，运用 Tensor Core、异步 IO、并行 Bitonic TopK 实现张量点积与 TopK 算子垂直融合。时延从 **30ms** 压缩至 **11ms**（**3x** 加速比）。
- Labeling** 模型量化部署 | 在线推理延迟优化
针对 Labeling 模型在线推理延迟过高的问题，根据场景特征差异化采用 SmoothQuant（compute-bound）与 GPTQ（memory-bound）量化部署。**P95** 延迟从 **6.7s** 降至 **4.4s**。

开源贡献

- vLLM** 核心 **Feature** 贡献者：作为 vLLM 核心贡献者，多项 PR 合入主线，涵盖投机解码、多模态模型支持、Async Scheduling 等方向。
- GitHub: <https://github.com/vllm-project/vllm/pulls?q=is%3Apr+author%3APatchouliTIS+is%3Aclosed>
- INT8 Blockwise W8A8** 在线量化专利化：INT8 Blockwise Dense/MoE 相关量化与算子融合方案已申请发明专利。
- GitHub: <https://github.com/PatchouliTIS/INT8BlockwiseGEMM>

教育背景

中国科学技术大学, 软件工程, 硕士研究生 2022.09 - 2025.06

GPA 3.4/4.3, 研究生二等奖学金。主修：分布式系统与云计算、深度学习、机器学习

技术能力

- 编程语言: 熟悉 C++ 面向对象编程与现代 C++ 语言特性；熟悉 Python 编程；熟悉 Linux 系统开发
- AI** 推理优化: 熟悉 PyTorch；熟悉 vLLM, TensorRT-LLM 等大模型推理框架；拥有 CUDA/Triton/CUTLASS 算子开发经验，掌握张量并行、模型并行、序列并行等分布式训练概念；掌握常用的神经网络推理优化方法（量化、投机解码、算子融合等）