

陈选安

(+86) 178-2650-7955 · 623894679@qq.com · AI Infra / 推理引擎工程师 · GitHub @PatchouliTIS

教育背景

中国科学技术大学, 软件工程, 硕士研究生	2022.09 - 2025.06
GPA 3.4/4.3 (TOP 25%), 研究生二等奖学金。主修：分布式系统与云计算、深度学习、机器学习	
长安大学, 道路桥梁与渡河工程, 工学学士	2015.09 - 2019.06
GPA 3.7/5.0 (TOP 10%), 院级一等奖学金。主修：C++ 程序设计、Python 程序设计、数据结构	

技术能力

- 编程语言: 熟悉 C++ 面向对象编程与现代 C++ 语言特性；熟悉 Python, Golang；熟悉 Linux 系统开发
- AI 推理优化: 熟悉 PyTorch, TensorFlow；熟悉 vLLM, TensorRT-LLM 等大模型推理框架；拥有 CUDA/Triton/CUTLASS 算子开发经验，掌握张量并行、模型并行、序列并行等分布式训练概念；掌握常用的神经网络推理优化方法（量化、投机解码、算子融合等）
- 工程组件: 熟悉 Kafka, ElasticSearch, Docker, CMake, Git；了解 Kubernetes 基本概念

工作经历

腾讯 TEG 混元机器学习平台, 推理引擎工程师	2025.06 - 2026.04
INT8 Blockwise W8A8 量化推理优化（专利成果）：针对 Ampere 硬件上 INT8 量化算子频繁执行数值转换影响算子性能的痛点，提出 INT8 Hybrid 两级 Scale 量化方案，将 FP32 scale 二次分解为 (Q_int32, F_fp32) 以实现 K-Tile 维度上连续 IMMA INT32 累加；在此基础上通过 CUTLASS 实现 CTA Swizzle 优化以及手动交替编排 k-Tile mainloop 内的 Idmatrix 与 IMMA 算子等方式，将 Tensor Core 利用率从 Triton 基础实现的 48% 提升至 65%，在多种 workload 下算子端到端时延降低 1.23x 1.47x；算子整合进 vLLM 框架后，编写 Triton Kernel 将激活在线量化的多步算子垂直融合成单算子，在 Qwen3-8B 模型上进行测试，端到端 QPS 相比 BF16 推理有 1.67x 2.24x 的提升。 Async N-gram GPU 投机解码（PR #29184 合入 vLLM 主线）：针对社区反馈以及业务场景中，高并发任务中 N-gram 负优化的问题，将 N-gram Proposer 完全迁移至 GPU，利用 Torch GPU 向量化操作将原始的 CPU O(N) 查找代价优化为使用滑动窗口的 O(1) 并行匹配，结合编译优化进一步压缩 N-gram 算子的性能；实现异步 D2H、Pinned Memory 复用、独立 CUDA Stream 等零同步设计，H20 上 64 512 并发吞吐提升 20%~39%。 Penalty-Aware Speculative Decoding：为 vLLM 框架的 speculative decoding (rejection sampler) 实现并集成 logit processors，修复了 bad_words、frequency/presence penalties 和 allowed_token_ids 在预测采样路径被忽略的问题，保证了在各种统计解码场景下的生成约束正确性；针对多 draft tokens 设计并行采样机制，在 Triton kernel 中以 BLOCK_SIZE 粒度向量化匹配 vocab ID，修正多 draft token 并行采样时的 frequency/presence penalty 计算错误。 DivPrune 视觉 Token 剪枝：针对多模态模型处理视频等流媒体时，encoder 阶段 vision token 过多的问题，基于 vLLM 框架在 Qwen3-VL 中设计并实现基于最远点采样（Farthest-Point Sampling）的特征多样性剪枝方法，采用批量并行选取（parallel_k=32）+ mRoPE 3D 位置编码附加方案，实现 EVS/DivPrune/关闭三种模式的无缝切换，保持完全向后兼容，在 Qwen3-VL 视频 Caption 等业务场景实现 1.2x 1.34x 端到端吞吐提升。 Eagle3 Hidden States 导出链路：复用 speculative decoding 基础设施，设计 cache-only drafter 将目标模型多层 aux_hidden_states 按 token 级位置 scatter 写入 GPU paged KV cache，打通 GPUModelRunner 到 KV Connector 的完整中间表征导出管线。	

实习经历

微软 Bing Core Search, 推理引擎性能优化工程师	2023.10 - 2024.12
KV Cache 压缩优化：基于注意力分数实现 KV Cache 压缩，使用 Triton 实现 Prefill 阶段 Block-Sparse Attention，编写 CUDA 内存搬运函数结合 vLLM CacheEngine 实现动态压缩存储，达到 60% 压缩率，4x kernel 加速比，A100 上 LLaMa-7B P95 时延从 9.8s 优化到 6.3s； Online TopK 算子融合：使用 CUTLASS & CuTe 框架，运用 Tensor Core、异步 IO、并行 Bitonic TopK 实现张量点积与 TopK 算子垂直融合，时延从 30ms 压缩至 11ms（3x 加速比） Labeling 模型量化部署：SmoothQuant 优化 compute-bound 场景 + GPTQ 优化 memory-bound 场景，P95 延迟从 6.7s 降至 4.4s 搜索排序模型优化：BERT 蒸馏训练引入 RoPE，使用 DeepSpeed ZeRO-2 + FP16 在 8xA100 上训练，达到基线 8x 训练速度	

项目经历

基于 RAG 的大语言模型私人知识库机器人	2023.12 - 2024.03
使用 AutoGPTQ 对 Llama-2-7B 进行 4bit 量化 + vLLM 推理；使用 Sentence-Transformer 微调 BGE 嵌入模型增强上下文感知能力，IR 质量提升 10%；基于随机森林的 Query 分类重排序，回答质量提升 24%	

基于 VGG19 的神经网络训练及寒武纪 MLU 算子实现	2023.04 - 2023.05
基于 VGG19 搭建图像风格迁移网络；使用寒武纪 MLU SIMD 函数实现 SoftMax、矩阵乘等算子，实现双流水线并行并融合进 TensorFlow 计算图，加速比达 2.4x	

开源贡献

- vLLM 核心贡献者**：多项 PR 合入主线，涵盖 INT8 量化推理、投机解码 GPU 化、视觉 Token 剪枝、Hidden States 导出等方向
- GitHub: <https://github.com/PatchouliTIS>