

陈选安

(+86) 178-2650-7955 · 623894679@qq.com · AI Infra / 推理引擎工程师 · GitHub @PatchouliTIS

教育背景

中国科学技术大学, 软件工程, 硕士研究生 2022.09 - 2025.06
GPA 3.4/4.3 (TOP 25%), 研究生二等奖学金。主修: 分布式系统与云计算、深度学习、机器学习
长安大学, 道路桥梁与渡河工程, 工学士 2015.09 - 2019.06
GPA 3.7/5.0 (TOP 10%), 院级一等奖学金。主修: C++ 程序设计、Python 程序设计、数据结构

技术能力

- 编程语言: 熟悉 C++ 面向对象编程与现代 C++ 语言特性; 熟悉 Python, Golang; 熟悉 Linux 系统开发
- AI 推理优化: 熟悉 PyTorch, TensorFlow; 熟悉 vLLM, TensorRT-LLM 等大模型推理框架; 拥有 CUDA/Triton/CUTLASS 算子开发经验, 掌握张量并行、模型并行、序列并行等分布式训练概念; 掌握常用的神经网络推理优化方法 (量化、投机解码、算子融合等)
- 工程组件: 熟悉 Kafka, ElasticSearch, Docker, CMake, Git; 了解 Kubernetes 基本概念

工作经历

腾讯 | TEG 混元机器学习平台, 推理引擎性能优化工程师 2025.06 - 2026.04

- vLLM INT8 Blockwise W8A8 量化推理优化: 提出 Hybrid 两级 Scale 量化方案, 将 FP32 scale 分解为 (Q_int32, F_fp32), GEMM 主循环全程 INT32 算术, 实现与 Tensor Core IMMA 完美 pipeline overlap; 基于 CUTLASS 2.x 开发 3 种 CTA Tile 配置的 hybrid GEMM kernel, 运行时按 M 维度自适应 dispatch; 实现 CTA Swizzle 优化, **L2 Hit Rate 从 49.8% 提升至 90.3%, Kernel 延迟降低 1.9x**; 设计 Triton 三级融合策略消除 eager dispatch 瓶颈, 端到端性能达 cuBLAS BF16 的 **1.72x (361 TFLOPS on A100)**
- Triton INT8 Kernel 深度优化: 通过 SASS 反汇编逆向分析 CUTLASS hybrid kernel, 将 Triton kernel 从三级 fp32 累加器重构为二级 INT32 累加器, 实现与 CUTLASS bit-exact 精度一致 (CosSim=1.0); 寄存器 spill 从 **13 条完全降至 0, PTX 虚拟寄存器 b64 减少 53%, Tensor Core 利用率从 41.6% 提升至 54.4%**; 定量归因剩余性能差距至 Triton compiler 的 instruction scheduling 与 SMEM layout 固有限制
- Async N-gram GPU 投机解码 (PR #29184 合入 vLLM 主线): 将 N-gram 提议器完全迁移至 GPU, 利用 Tensor.unfold() 构建 O(1) 滑动窗口并行匹配, 结合 torch.compile + torch.inductor 编译优化; 实现异步 D2H、Pinned Memory 复用、独立 CUDA Stream 等零同步设计, **H20 上中等并发吞吐提升 20%~39%**
- Penalty-Aware Speculative Decoding (合入 vLLM 主干): 设计增量计数机制与编译期循环展开 (tl.static_range), 在 Triton kernel 中以 BLOCK_SIZE 粒度向量化匹配 vocab ID, 修正多 draft token 并行采样时的 frequency/presence penalty 计算错误
- DivPrune 视觉 Token 剪枝: 在 Qwen3-VL 中设计并实现基于最远点采样 (Farthest-Point Sampling) 的特征多样性剪枝方法, 采用批量并行选取 (parallel_k=32) + mRoPE 3D 位置编码附加方案, 实现 EVS/DivPrune/关闭三种模式的无缝切换, 保持完全向后兼容
- Eagle3 Hidden States 导出链路: 复用 speculative decoding 基础设施, 设计 cache-only drafter 将目标模型多层 aux_hidden_states 按 token 级位置 scatter 写入 GPU paged KV cache, 打通 GPUModelRunner 到 KV Connector 的完整中间表征导出管线

实习经历

微软 | Bing Core Search, 推理引擎性能优化工程师 2023.10 - 2024.12

- KV Cache 压缩优化: 基于注意力分数实现 KV Cache 压缩, 使用 Triton 实现 Prefill 阶段 Block-Sparse Attention, 编写 CUDA 内存搬运函数结合 vLLM CacheEngine 实现动态压缩存储, **达到 60% 压缩率, 4x kernel 加速比**, A100 上 P95 时延从 9.8s 优化到 6.3s
- Online TopK 算子融合: 使用 CUTLASS/CuTe 框架, 运用 Tensor Core、异步 IO、并行 Bitonic TopK 实现张量点积与 TopK 算子融合, **时延从 140ms 压缩至 11ms (12x~15x 加速比)**
- Labeling 模型量化部署: SmoothQuant 优化 compute-bound 场景 + GPTQ 优化 memory-bound 场景, **P95 延迟从 6.7s 降至 4.4s**
- 搜索排序模型优化: BERT 蒸馏训练引入 RoPE, 使用 DeepSpeed ZeRO-2 + FP16 在 8xA100 上训练, **达到基线 8x 训练速度**

腾讯 | CSIG, 软件开发实习生 2023.06 - 2023.09

- 数据传输服务构建: 基于 MySQL 主从复制原理, 使用 Canal 增量订阅从 0 到 1 完成 MySQL-Canal-Kafka 数据传输服务, 替换 JDBC Kafka Connect 方案, **QPS 提升至 176%**

项目经历

基于 RAG 的大语言模型私人知识库机器人 2023.12 - 2024.03

- 使用 AutoGPTQ 对 Llama-2-7B 进行 4bit 量化 + vLLM 推理; 使用 Sentence-Transformer 微调 BGE 嵌入模型增强上下文感知能力, **IR 质量提升 10%**; 基于随机森林的 Query 分类重排序, **回答质量提升 24%**

基于 VGG19 的神经网络训练及寒武纪 MLU 算子实现 2023.04 - 2023.05

- 基于 VGG19 搭建图像风格迁移网络; 使用寒武纪 MLU SIMD 函数实现 SoftMax、矩阵乘等算子, 实现双流水线并行并融合进 TensorFlow 计算图, **加速比达 2.4x**

开源贡献

- vLLM 核心贡献者: 多项 PR 合入主线, 涵盖 INT8 量化推理、投机解码 GPU 化、视觉 Token 剪枝、Hidden States 导出等方向
- GitHub: <https://github.com/PatchouliTIS>